Angewandte Datenanalyse mit R

Andreas Mock

Nationales Centrum für Tumorerkrankungen (NCT) Heidelberg

Sommersemester 2018

Hands-On Praktikum: Angewandte Datenanalyse mit R

Organisatorisches SS 2018

Kursunterlagen: http://andreasmock.github.io/teaching

Kontakt: andreas.mock@med.uni-heidelberg.de

Ort: K1, NCT 1.OG

Kurszeiten

- 05.06.2018 - 15:30 - 17:00 Uhr
- 12.06.2018 - **16:30** - **18:00 Uhr**
- 26.06.2018 - 15:30 - 17:00 Uhr

Translationale Onkologie 2018

Was ist R?

- `R` ist eine **freie Programmiersprache** für statistische Berechnungen und Grafiken.
- Obwohl `R` bereits alt ist (Erscheinungsjahr 1993) gilt diese als **Standardsprache** für statistische Problemstellungen in Wirtschaft und Wissenschaft
- $>$ **11.000 Formelsammlungen** für spezifische Fragestellungen (sog. Pakete)
- Hoch-qualitative und individuelle **Grafiken** - viele Wissenschaftler benutzen `R` nur hierzu
- Sowohl `R`, als auch alle Pakete sind **kostenlos**!!

RStudio

Grafische Benutzeroberfläche und Entwicklungsumgebung für R

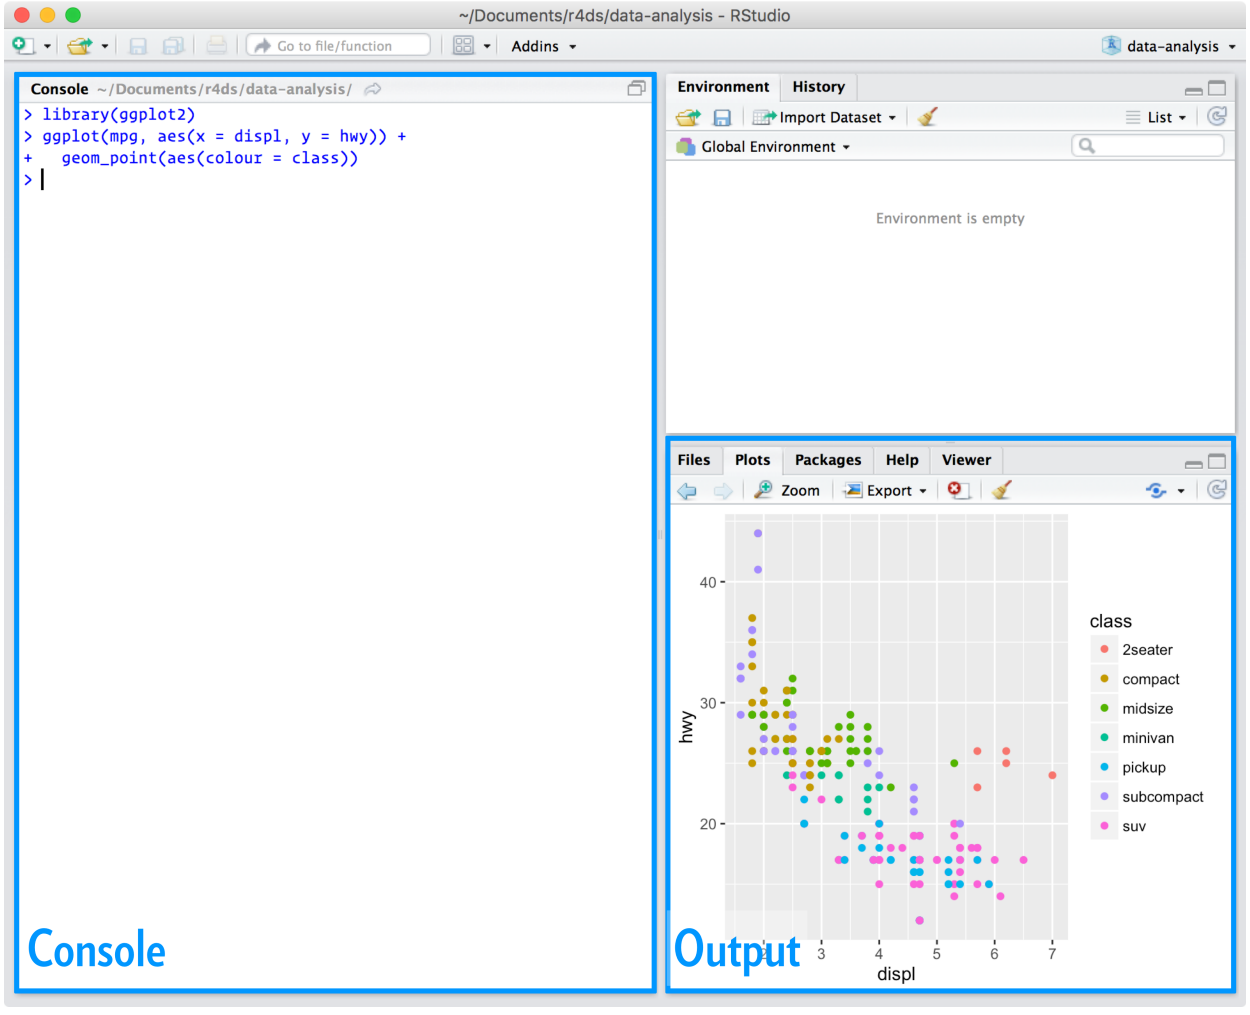

R for Data Science, Hadley Wickham & Garrett Grolemund 2016

Data Science

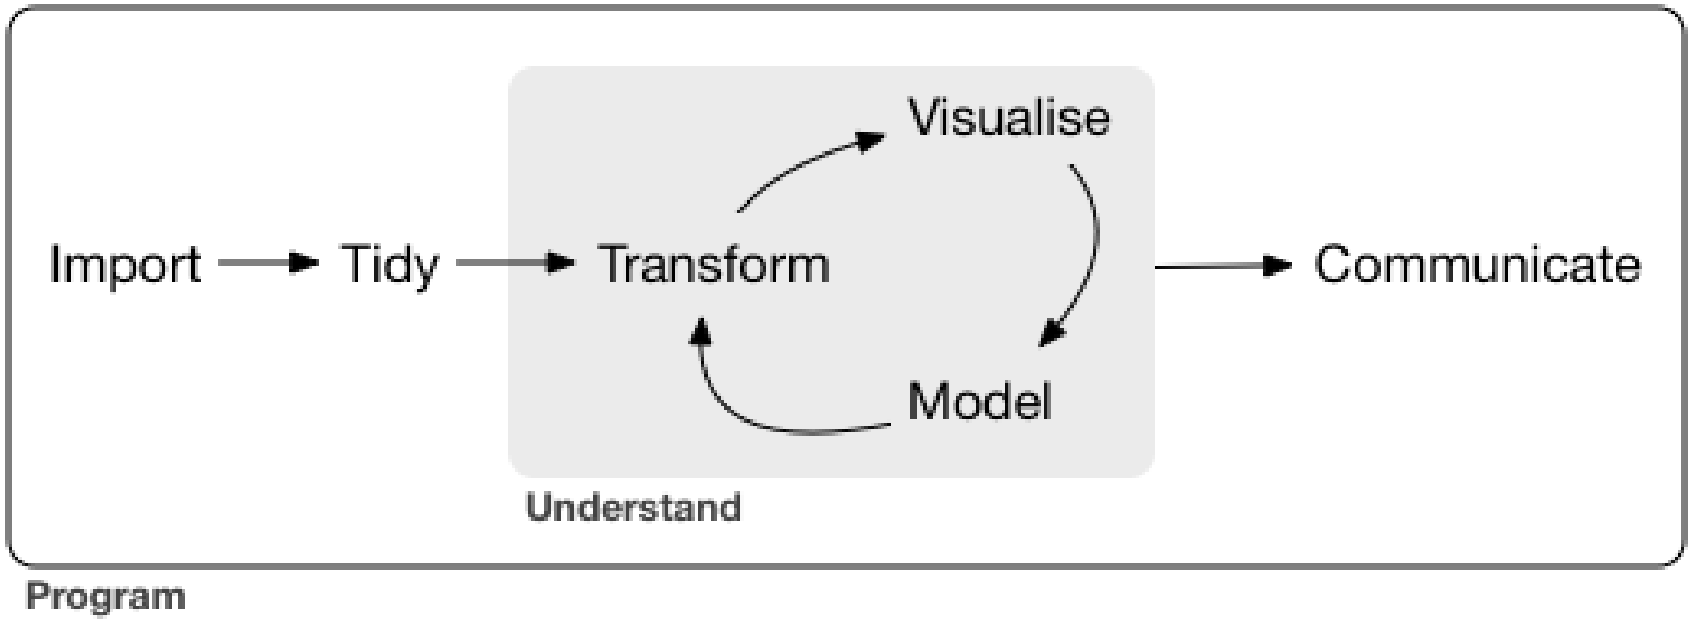

R for Data Science, Hadley Wickham & Garrett Grolemund 2016

Weiterführende Literatur

Programmieren mit R
Hands-On Programming with R, Garrett Grolemund
- Kapitel 1, 2, 3, 4, 5, 7, 9
Link

Die "Bibel" für R User
R for Data Science, Hadley Wickham & Garrett Grolemund
Link

Kochbuch für R Plots
R Graphics Cookbock, Winston Chang
Link

Installations- und Kaffeepause

R Coding 101

R Architektur

R ist eine Objekt-orientierte Programmiersprache. Es dreht sich daher im Grunde alles darum Objekte herzustellen, zu manipulieren und zu visualisieren.

```
# Zuweisung von Zahlen zu einem Objekt
alter <- 67
```

R ist *case-sensitive* - Groß- und Kleinschreibung ist wichtig!

```
# Objekt `alter` ausgeben
alter
```

```
## [1] 67
```

```
# .. entspricht nicht
Alter
```

```
## Error in eval(expr, envir, enclos): object 'Alter' not found
```

R Objekttypen

Vektor

Def: Sammlung mehrerer Objekte gleicher Art (Länge 1 ist möglich).

```
# numerischer Vektor mit Länge 1
x1 <- 5

# Charaktervektor mit Länge 1 (wird in "" gesetzt)
x2 <- "green"

# Vektoren mit Länge 3
y1 <- c(1,3,9)
y2 <- c("gene1","gene2","gene3")
```

Subsetting:

```
# um den vollständigen Vektor y2 auszugeben
y2
```

```
## [1] "gene1" "gene2" "gene3"
```

```
# um nur die ersten beiden Einträge des Vektors y2 auszugeben
y2[1:2]
```

```
## [1] "gene1" "gene2"
```

R Objekttypen

Matrix

Kombination mehrerer Vektoren gleichen Typs (numerisch oder Charakter). Die Matrix kann Zeilen- und Spaltennamen haben.

```
matrix <-  cbind(y1, y1, y1)
rownames(matrix)  <-  y2
colnames(matrix) <-  c("sample1","sample2","sample3")
matrix
```

```
##       sample1 sample2 sample3
## gene1       1       1       1
## gene2       3       3       3
## gene3       9       9       9
```

R Objekttypen

Matrix

Ein Subset kann man sich mit der folgenden Syntax anzeigen lassen:

```
matrix[Zeile,Spalte]
```

Bespiele hierfür sind:

```
matrix[1,]
```

```
## sample1 sample2 sample3
##       1       1       1
```

```
matrix[,3]
```

```
## gene1 gene2 gene3
##     1     3     9
```

```
matrix[1:2,]
```

```
##       sample1 sample2 sample3
## gene1       1       1       1
## gene2       3       3       3
```

R Objekttypen

Dataframe

Im Gegensatz zu Matrizen können in *Dataframes* Vektoren verschiedener Typen (z.B. numerischer Vektor und Charaktervektor) miteinander kombiniert werden. Wichtig: Die Vektoren müssen die gleiche Länge haben.

```
df <- data.frame(age=c(50,47,87),
                 gender=c("male","male","female"))
df
```

```
##   age gender
## 1  50   male
## 2  47   male
## 3  87 female
```

Somit eignen sich *Dataframes* insbesondere für die Analyse von Patientenmetadaten im Rahmen von molekularbiologischen Experimenten oder klinischen Studien.

R Objekttypen

Vektor

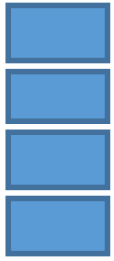

1 Spalte bzw. Reihe
1 Typ (numerisch oder Text)

Matrix

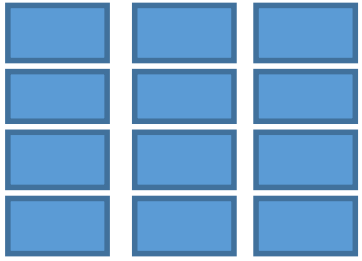

Multiple Spalten / Reihen
1 Typ (numerisch oder Text)

Dataframe

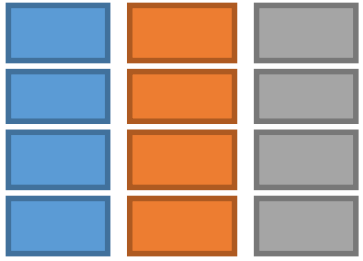

Multiple Spalten / Reihen
mehrere Typen (z.B. numerisch und Text)

R Objekttypen

Funktionen

Die Grundsyntax einer jeden Funktion ist

```
function(Objekt, Argumente)
```

Die Argumente sind hierbei fakultativ. R besitzt eine Vielzahl von Funktionen, ohne dass zusätzliche Packete geladen werden müssen.

```
sum(y1)
```

```
## [1] 13
```

```
mean(y1)
```

```
## [1] 4.333333
```

Die Funktion `help` öffnet die Dokumentation in RStudio und zeigt die notwendigen Objekte und Argumente zu jeder Funktion an. Als Beispiel, was genau macht die Funktion `cbind`?

```
help(cbind)
```

Bespieldaten des Kurses

Metadaten des *The Cancer Genome Atlas (TCGA)* zur Analyse von Kopf-Hals-Tumoren (head and neck squamous cell carcinoma; HNSCC). Der Datensatz fasst die wichtigsten klinisch-pathologischen Charakteristika der Studienkohorte (n=279) zusammen.

Link zur Originalpublikation

Bespieldaten des Kurses

```
head(hnscc)
```

```
##             id age alcohol days_to_death gender  neoplasm_site grade
## 1 TCGA-BA-4074  69     YES           461   MALE    Oral Tongue    G3
## 2 TCGA-BA-4076  39     YES           415   MALE         Larynx    G2
## 3 TCGA-BA-4077  45     YES          1134 FEMALE Base of Tongue    G2
## 4 TCGA-BA-4078  83      NO           276   MALE         Larynx    G2
## 5 TCGA-BA-5149  47     YES           248   MALE Floor of Mouth    G2
## 6 TCGA-BA-5151  72     YES           190   MALE  Buccal Mucosa    G1
##   pack_years                                tabacco_group tumor_stage
## 1         51                                Current smoker   Stage IVA
## 2         30                                Current smoker        <NA>
## 3         30 Current reformed smoker for < or = 15 years   Stage IVA
## 4         75 Current reformed smoker for < or = 15 years        <NA>
## 5         60                                Current smoker   Stage IVA
## 6         20      Current reformed smoker for > 15 years   Stage IVA
##   vital_status
## 1     DECEASED
## 2     DECEASED
## 3     DECEASED
## 4     DECEASED
## 5       LIVING
## 6       LIVING
```